

GPT et infrastructure technologique

Explication simple pour comprendre ce que signifie GPT et ce qu'il faut pour construire un grand système d'intelligence artificielle.

Objectif : expliquer clairement GPT, les GPU, les serveurs, le stockage, le réseau, le refroidissement et l'énergie nécessaires.

[GPT] GPT veut dire quoi ?

GPT veut dire : Generative Pre-trained Transformer.

En français : Transformateur génératif pré-entraîné.

GEN	Generative - génératif GPT peut produire du contenu : texte, réponses, idées, code, résumés et explications.
PRE	Pre-trained - pré-entraîné GPT a été entraîné à l'avance sur de très grandes quantités de textes. Il apprend des structures, des relations et des probabilités entre les mots.
TRF	Transformer - transformateur Le transformateur est l'architecture technique qui aide le modèle à comprendre les relations entre les mots et à produire des réponses cohérentes.

[OK] En résumé

GPT est un modèle d'intelligence artificielle entraîné pour comprendre et générer du langage humain.

Il ne pense pas comme un humain. Il calcule des réponses à partir de données, de probabilités et de modèles mathématiques.

[INFRA] Quelle infrastructure faut-il pour créer et faire fonctionner GPT ?

Pour créer et faire fonctionner un système comme GPT, il faut une infrastructure comparable à un centre de calcul industriel.

Ce n'est pas seulement un logiciel installé sur un ordinateur classique. Il faut une infrastructure massive composée de serveurs, processeurs spécialisés, stockage, réseau, refroidissement et énergie.

SRV Serveurs puissants

Des serveurs spécialisés contenant des milliers de GPU. Ils exécutent les calculs nécessaires à l'entraînement et à l'utilisation du modèle.

GPU GPU spécialisés

Le GPU, ou processeur graphique, réalise énormément de calculs en parallèle. Il est devenu essentiel pour l'intelligence artificielle.

STO Stockage massif

Plusieurs pétaoctets peuvent être nécessaires pour stocker les données brutes, les données nettoyées, les modèles, les sauvegardes et les résultats.

NET Réseau très rapide

Les serveurs doivent échanger les données à très haute vitesse, souvent autour de 400 Gbit/s par serveur GPU ou plus.

COOL Refroidissement

Les GPU produisent beaucoup de chaleur. Il faut du refroidissement par air, par liquide ou des systèmes industriels spécialisés.

NRJ Énergie

Les grands centres d'IA consomment de très grandes quantités d'électricité, parfois comparables à des installations industrielles lourdes.

[CHIFFRES] Ordres de grandeur

Les chiffres ci-dessous sont des estimations réalistes. Les architectures exactes des grands fournisseurs ne sont pas entièrement publiques.

Élément	Estimation
GPU	10 000 à 100 000+
SRV Serveurs	1 250 à 12 500 serveurs de 8 GPU
STO Stockage	Plusieurs pétaoctets
NET Réseau	400 Gbit/s ou plus
NRJ Énergie	Dizaines à centaines de GWh
Coût	Millions à milliards de dollars

[EXEMPLE] Exemple simple de consommation

Un groupe de 1 000 GPU H100 peut consommer environ 1 à 2 MW avec les serveurs, le réseau et le refroidissement.

Sur un mois, cela peut représenter environ 1 GWh d'électricité.

Pour 10 000 GPU, on peut monter autour de 10 à 15 GWh par mois.

Taille approximative	Consommation mensuelle
1 000 GPU	Environ 1 GWh
10 000 GPU	Environ 10 à 15 GWh

[CONCLUSION] Conclusion

GPT n'est pas seulement un logiciel.

C'est un système d'intelligence artificielle appuyé sur une infrastructure massive : serveurs, GPU, stockage, réseau, refroidissement et énergie.

En résumé : GPT est une intelligence artificielle de langage, mais derrière elle se trouve une véritable infrastructure industrielle de calcul.

[NOTE] Note

Les chiffres présentés sont des ordres de grandeur pédagogiques. Ils peuvent varier selon la taille du modèle, le type de GPU, la durée d'entraînement, le rendement énergétique du centre de données et le niveau d'utilisation.